

MAT703. Parcial Fausto Fabian Crespo
Fernandez

Fausto Fabian Crespo Fernandez

junio 2016

0.1. Ejercicio 1

Solución

- (a) Como la media de una distribución exponencial es $1/\lambda$ entonces $y_i \sim \text{Exp}(1/\lambda)$ y la apriori no informativa para el parámetro es $p(\lambda) \propto 1/\lambda$. Se escoge una muestra aleatoria de datos y_1, y_2, \dots, y_n , entonces la a posteriori es

$$\begin{aligned} p(\lambda|y_1, y_2, \dots, y_n) &\propto p(\lambda)p(y_1, y_2, \dots, y_n|\lambda) \\ &= \frac{1}{\lambda} * \left(\frac{1}{\lambda}e^{-\frac{y_1}{\lambda}}\right) * \dots * \left(\frac{1}{\lambda}e^{-\frac{y_n}{\lambda}}\right) \\ &= \frac{1}{\lambda^{n+1}}e^{-\frac{1}{\lambda}\sum_{i=1}^n y_i} \\ &= \frac{1}{\lambda^{n+1}}e^{-\frac{n}{\lambda}\bar{y}} \end{aligned}$$

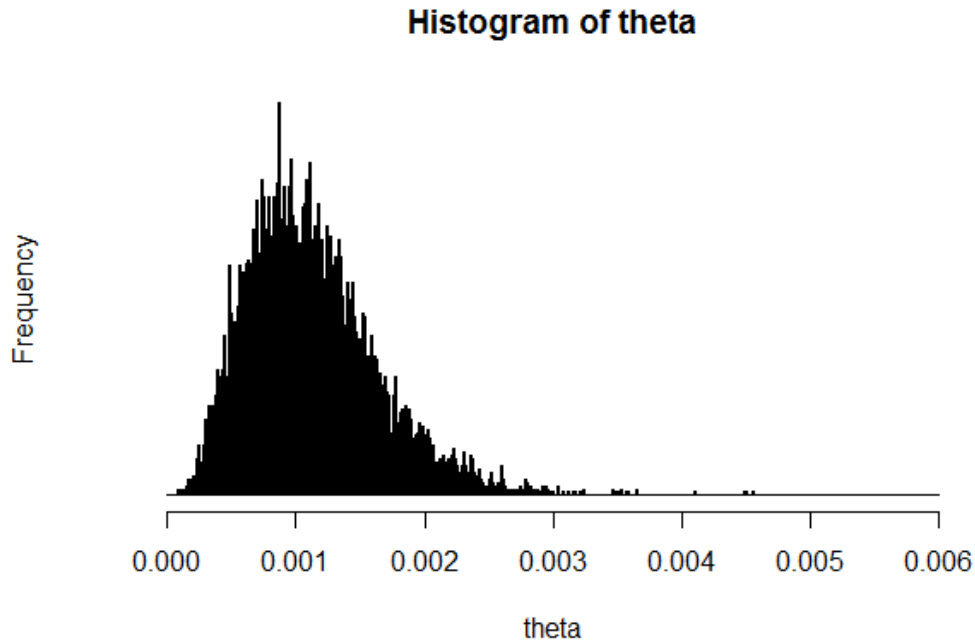
- (b) Para este modelo los estadísticos suficientes son la media de la muestra \bar{y} y el número de datos o sea de elementos de la muestra n

- (c) Si usamos la transformación $\theta = \frac{1}{\lambda}$ entonces usando principio de invarianza de Jeoffreys

$$\begin{aligned} p(\theta|\text{datos}) &= p(\lambda|\text{datos})\left|\frac{d\theta}{d\lambda}\right|^{-1} = \frac{1}{\lambda^{n+1}}e^{-\frac{n}{\lambda}\bar{y}} * \lambda^2 = \lambda^{2-n-1}e^{-\frac{n}{\lambda}\bar{y}} \\ &= (\lambda^{-1})^{n-1}e^{-n\bar{y}\frac{1}{\lambda}} = (\theta)^{n-1}e^{-n\bar{y}\theta} \text{ o sea } \theta|y \sim \text{Gamma}(n, n\bar{y}) \end{aligned}$$

- (d y e) Las duraciones de un componente tienen una distribución exponencial pues esta distribución no tiene memoria y entonces en R

```
y = c(751, 594, 1213, 1126, 819);
n = length(y);
nsim = 10000;
media.datos = sum(y)/n;
theta = rgamma(nsim, shape = n, rate = n * media.datos);
print(theta);
hist(theta, xlab = "theta", yaxt = "n",
breaks = seq(0, 0,006, ,00001), cex = 2);
print(mean(theta));
deciles = quantile(theta, probs = c(0,1, 0,2, 0,3, 0,4, 0,5, 0,6, 0,7, 0,8, 0,9))
print(deciles)
```



Con media de θ de 0.001119726 y deciles de

10 % 20 % 30 % 40 % 50 % 60 % 70 % 80 % 90 %

0.0005396771 0.0006897657 0.0008140539 0.0009266420 0.0010517611 0.0011753536
0.0013249122 0.0015062644 0.0017853703

0.2. Ejercicio 2

Solución

- (a) Como $y^{(k)} = 101$ entonces $N \geq 101$ Para algunos valores de U por ejemplo $U = 102, 120, 150, 200, 1000$,calculamos para los distintos valores de U las probabilidades de los valores de N en $y^k \leq N \leq U$ y calculamos las media ,tenemos en R

```

U = c(120, 150, 200, 1000, 10000)
y = c(44, 31, 99, 25, 101)
max.y = max(y)
k = length(y)
for(i in 1:length(U)){
  N = seq(max.y, U[i], 1)
  p = 1/(N^k)
  print(mean(p))
}

```

lo que da

```

[1]6,323691e-11
[1]3,926275e-11
[1]2,295723e-11
[1]2,722408e-12
[1]2,475168e-13

```

Como se ve a medida que aumenta U disminuye la probabilidad media.
y podemos tomar mas valores de U . En R

```

U=seq(102,10000,1)
y=c(44,31,99,25,101)
max.y=max(y)
k=length(y)
medias=c()
for (i in 1:length(U)){
  N=seq(max.y,U[i],1)
  p=1/(N^k)
  medias = append(medias, mean(p))
}
hist(medias, xlab = "medias", yaxt = "n",
breaks = seq(0, 0,000000000001, ,00000000001), cex = 2);
print(mean(medias));

```

lo que da una media 1.575562e-12

- (b) El valor esperado de $N|y$ es $E[N|y] = \sum_{i=\max(y)}^U i * \frac{1}{i^k} = \sum_{i=101}^U i * \frac{1}{i^5} =$
 $\sum_{i=101}^U \frac{1}{i^4}$
 $= \frac{1}{101^4} + \frac{1}{102^4} + \dots + \frac{1}{U^4}$ (asumiendo U conocida)

Si U es desconocida entonces habría que

$[E[N|y]] = E[E[N|y, U]]$ donde la última esperanza se toma por U

La desviación estándar de $N|y$ es la raíz cuadrada de la varianza que es

$$Var(N|y) = E(N^2|y) - [E(N|y)]^2 = E[(N|y - E(N|y))^2] = \sum_{i=101}^U (i - \frac{1}{101^4} + \frac{1}{102^4} + \dots + \frac{1}{U^4})^2 * \frac{1}{i^5} = \frac{1}{101^3} + \frac{1}{102^3} + \dots + \frac{1}{U^3} - (\frac{1}{101^4} + \frac{1}{102^4} + \dots + \frac{1}{U^4})$$

0.3. Ejercicio 3

Solución

Tenemos que y es el número de aciertos de la carta extraída y llamemos p la probabilidad de adivinar correctamente en un experimento. La variable y dado p tiene una distribución binomial $Bin(20, p)$. O sea $p(y|p) = \binom{20}{y} p^y (1-p)^{20-y}$. La distribución a posteriori de p dado los datos y o sea el sujeto adivino $y = 8$ veces es (asumiento a priori para p no informativa $Beta(1,1)$) : $Beta(y+1, n-y+1) = Beta(9, 20-8+1) = Beta(9, 13)$

- (a) En R
`pbeta(0.2, shape1=9, shape2=13, ncp = 0, lower.tail = FALSE)`
 que da 0.985586 o sea la probabilidad de rechazar la hipótesis nula que es mayor que 0.2 es 0.01441396 y se acepta que el sujeto no está solo adivinando 0 sea que tiene algún conocimiento previo que le permite aceptar más que si $p = 0,2$
- (b) La a posteriori $Pr(p = 0,2|y = 8) = \frac{Pr(p=0,2)Pr(y=8|p=0,2)}{Pr(p=0,2)Pr(y=8|p=0,2) + Pr(p \neq 0,2)Pr(y=8|p \neq 0,2)}$

$$= \frac{0,5 * \binom{20}{8} (0,2)^8 (0,8)^{12}}{0,5 * \binom{20}{8} (0,2)^8 (0,8)^{12} + 0,5 * \binom{20}{8} (Beta(1,4))^8 (1-Beta(1,4))^{12}}$$

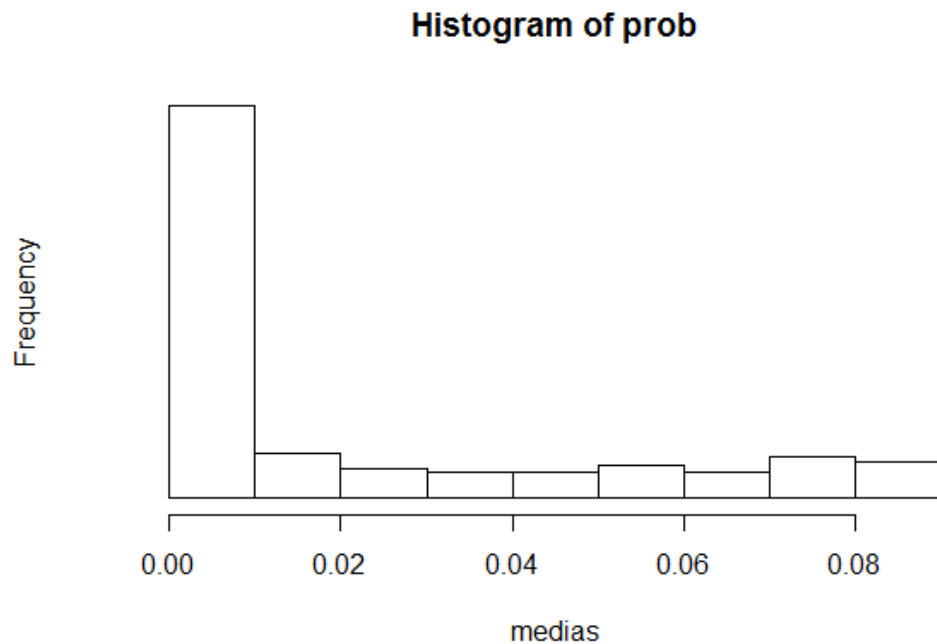
 Usando simulación en R

```

p1 = 0,2
nsim = 1000
prob = numeric(nsim)
for(iin1 : nsim){
  y1 = dbinom(8, 20, p1)
  p2 = rbeta(1, shape1 = 1, shape2 = 4);
  y2 = dbinom(8, 20, p2)
  prob[i] = y1/(y1 + y2)
}
print(mean(prob))
    
```

```
print(sum(prob > 0,2))
hist(prob, xlab = "medias", yaxt = "n", cex = 2);
```


Con lo que se obtiene que la media de la probabilidad es $0,02096575 < 0,05$




O sea el mismo resultado de rechazar la hipótesis nula de que $p = 0,2$


- (c) La probabilidad medias de la simulación para $Beta(0,5, 2)$ es 0.01576131, para $Beta(2, 8)$ es 0.02204103 y para $Beta(8, 32)$ es 0.01628791. Todos son probabilidades pequeñas lo que indica que en los tres casos se puede rechazar que $p = 0,2$. Las gráficas respectivas son

Histogram of prob



Histogram of prob





- (d) Si, asumiendo varias distribuciones a prioris de parámetro p se tienen que en todos los casos se puede rechazar la hipótesis de que $p = 0,2$.

0.4. Ejercicio 4

Solución

Las muertes siguen una distribución de Poisson con parámetro $e\lambda$ y si la a priori para λ es $Gamma(\alpha, \beta)$, entonces la a posteriori es $Gamma(\alpha + \sum_{i=1}^{10} y_i, \beta + \sum_{i=1}^{10} e_i)$ y $\sum_{i=1}^{10} e_i = 12435$ y $\sum_{i=1}^{10} y_i = 22$

- (a) Aquí se asume a priori no informativa. Tenemos

$$p(y_i) = Poisson(e_i \lambda) = \frac{e^{-e_i \lambda} (e_i \lambda)^{y_i}}{y_i!} \text{ y la verosimilitud es}$$

$$p(y_1, \dots, y_{10} | \lambda) = \prod_{i=1}^{10} \frac{e^{-e_i \lambda} (e_i \lambda)^{y_i}}{y_i!}$$

$$\propto e^{-(\sum_{i=1}^{10} e_i) \lambda} \lambda^{\sum_{i=1}^{10} y_i}$$

y como se asume una a priori no informativa para λ o sea $p(\lambda) \propto 1/\lambda$

La a posteriori es $p(\lambda|y_1, \dots, y_{10}) \propto e^{-(\sum_{i=1}^{10} e_i)\lambda} \lambda^{\sum_{i=1}^{10} y_i - 1}$
 O sea $Gamma(\sum_{i=1}^{10} y_i, \sum_{i=1}^{10} e_i) = Gamma(22, 12435)$

- (b) Si conocemos aproximadamente las probabilidades de que el parámetro λ siga la a priori no informativa (inciso a)) y la probabilidad de que siga la a priori $Gamma(\alpha, \beta)$ entonces podemos hacer estimaciones de los parámetros α y β usando la fórmula de Bayes. Además podemos comparar las dos distribuciones y obtener estimaciones de una a partir de la otra o también podemos partir de una a priori no informativa, obtener la a posteriori y luego usar esta a posteriori como a priori nuevamente.
- (c) Si en nuestro hospital hubo 2 muertes entonces $y_1 = 2$ y $e_1 = 1050$ y con esto, la distribución a posteriori usando el resultado de a) $Gamma(2, 1050)$ (asumiendo a priori no informativa)
 Si asumimos a priori $Gamma(\alpha, \beta)$ entonces la a posteriori sería $Gamma(\alpha + 2, \beta + 1050)$. Podemos usar $\alpha = 22$ y $\beta = 12435$ o sea usar la a posteriori (empezando con la no informativa) como a priori .
- (d) La distribución predictiva a priori es $p(y) = \int p(\lambda)p(y|\lambda)d\lambda$ y sabemos que $\lambda \sim Gamma(\alpha, \beta)$ y que $p(y|\lambda) \sim Poisson(e\lambda)$. Ahora tomamos específicamente $\lambda = \alpha/\beta$ que es la media de la distribución gamma y además podemos tomar $\alpha = 22, \beta = 12435$. Podemos asumir que la predicción de la cantidad de muertes un nuevo hospital, sigue una distribución $Poisson(\bar{e}\lambda) = Poisson(\bar{e}(\alpha/\beta)) = Poisson((12435/10) * (22/12435))$. En R

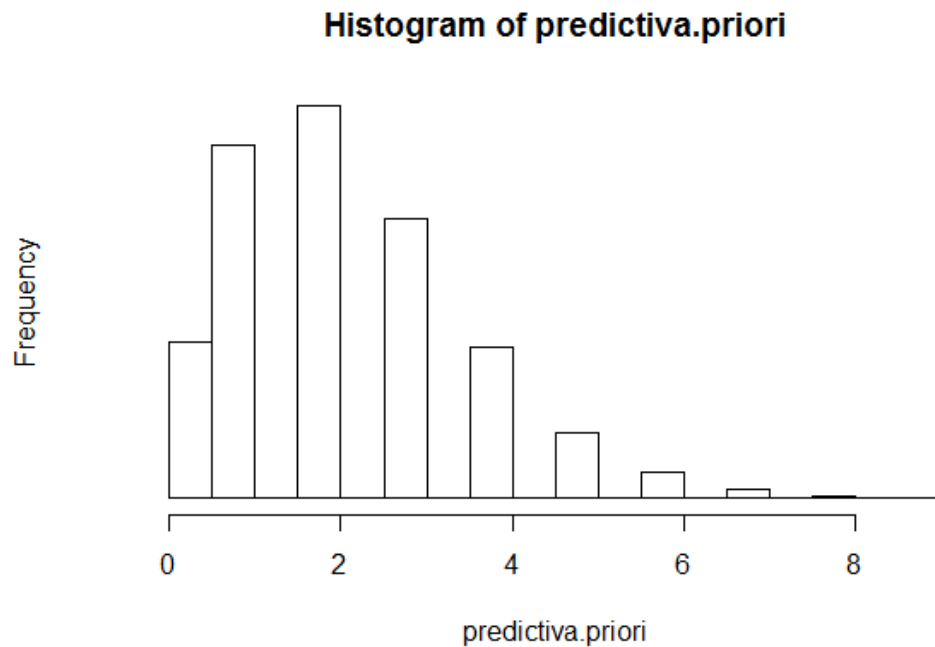
```
nsim = 10000
alpha = 22
beta = 12435
ndatos = 10
lambda = alpha/beta
predictiva.priori = numeric(nsim)
for(i in 1 : nsim)
{
  p.priori.gamma <- rgamma(1, alpha, beta)
```

```

predictiva.priori[i] = rpois(1, (beta/ndatos) * lambda)
}
hist(predictiva.priori, xlab = "predictiva.priori", yaxt = "n", cex =
2)
print(mean(predictiva.priori))
deciles = quantile(predictiva.priori, probs = c(0,1, 0,2, 0,3, 0,4, 0,5, 0,6, 0,7, 0,8, 0,9))
print(deciles)

```

Con lo que la media de la distribución es 2.2134 y el gráfico es



- (e) Para este hospital podemos predecir la cantidad de muertes en base a los datos anteriores. y tambien podemos calcular la probabilidad de 7 muertes con una exposición de 1845 dados los datos anteriores. Tenemos

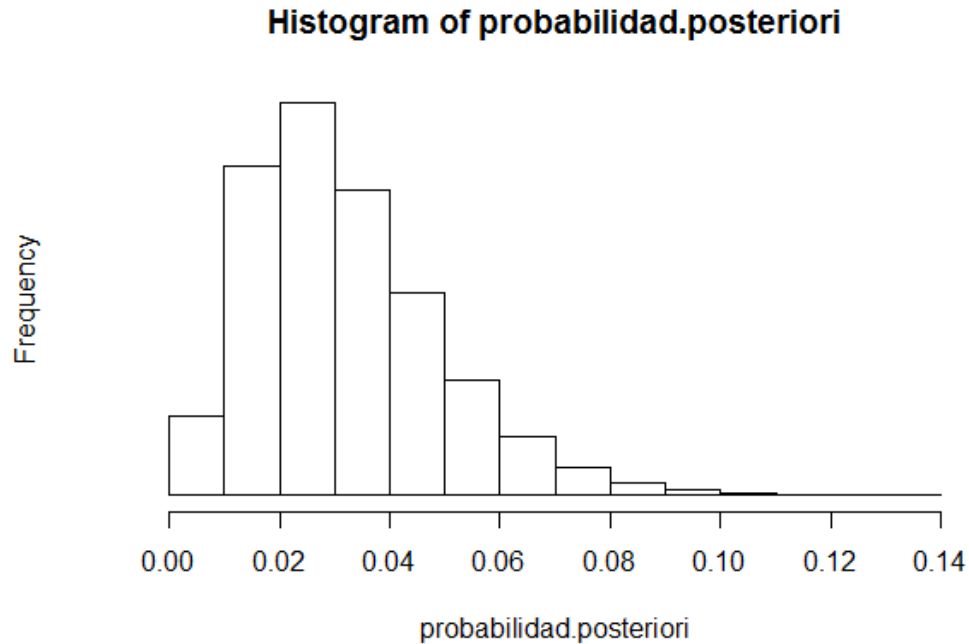
$$p(\tilde{y}|y) = \int p(\lambda|y)p(\tilde{y}|\lambda)d\lambda$$

y como la primera parte es la a posteriori que es $\text{Gamma}(\alpha + 22, \beta + 12435)$ (se asume que se empezó con una priori que es la posteriori de cuando se empezó con la no informativa o sea en este caso $\alpha = 22$)

```

y  $\beta$  = 12435 Tenemos que la segunda parte de la integral es una
Poisson( $1845 * \lambda$ )
entonces en R:
nsim = 100000
alpha = 22
beta = 12435
y = 7
e = 1845
probabilidad.posteriori = numeric(nsim)
for(iin 1 : nsim)
{
p.posteriori.gamma <- rgamma(1, alpha + alpha, beta + beta)
probabilidad.posteriori[i] = dpois(7, e * p.posteriori.gamma)
}
hist(probabilidad.posteriori, xlab = "probabilidad.posteriori", yaxt =
"n", cex = 2)
print(mean(probabilidad.posteriori))
deciles = quantile(probabilidad.posteriori,
probs = c(0,1,0,2,0,3,0,4,0,5,0,6,0,7,0,8,0,9,0,94,0,945,0,947,0,949,0,95,0,97))
print(deciles)

```



La media de esta distribución que representa la probabilidad de 7 muertes con exposición de 1854 dado los datos anteriores es 0.03205441 o sea menor que 0.05 y los datos de este hospital no son muy consecuentes con este modelo.

Otra forma de verlo es analizar el intervalo al 95% de confianza del número de muertes para este modelo. En R

```
nsim = 100000
alpha = 22
beta = 12435
y = 7
e = 1845
predictiva.posteriori = numeric(nsim)
p.posteriori.gamma <- rgamma(nsim, alpha + alpha, beta + beta)
y = rpois(nsim, e * p.posteriori.gamma)
hist(y, xlab = "y", yaxt = "n", cex = 2)
print(mean(y))
deciles = quantile(y, probs = c(0,025, 0,1, 0,2, 0,3, 0,4, 0,5, 0,6, 0,7, 0,8, 0,9, 0,975))
print(deciles)
```

```
print(sort(y)[c(0,025 * nsim, 0,95 * nsim)])
```

Lo que da que la media de muertes de 3.257 y el intervalo de confianza al 95 % es $[0, 7]$ y el decil 90 % es 6 con lo que con probabilidad menor de 0.1 la cantidad de muertes será 7 o más, el gráfico es

